

基于 TAO 主观诊断偏差性的分类应用

周亚琪¹, 付 潇², 郑 文¹⁺

(1. 太原理工大学 大数据学院 公共安全大数据研究所, 山西 太原 030060;

2. 中国船舶集团有限公司综合技术经济研究院 舰船文化产业发展研究中心, 北京 100081)

摘要: 甲状腺相关眼病是一种早期病理特征不明显的常见慢性致盲性眼眶疾病, 为解决诊断过程中医生主观诊断偏差导致的误诊问题, 提出一种基于复合模型缩放方法的模型 Efficient-TAO。通过优化训练过程, 改进动态激活函数和随机权重平均机制提高性能, 通过图像预处理算法实现眼肌 CT 图像数据的直接训练。实验结果表明, 模型的分类准确率达到 98.34%, 在其它算法评价指标中均表现良好。可视化结果进一步验证了 Efficient-TAO 算法在疾病分类中的可信度。

关键词: 甲状腺相关眼病; Efficient-TAO; 复合模型缩放; 模型优化; 医学图像分类; 图像预处理; 可信度

中图法分类号: TP181 **文献标识号:** A **文章编号:** 1000-7024 (2024) 09-2828-07

doi: 10.16208/j.issn1000-7024.2024.09.036

Application of classification based on TAO subjective diagnostic bias

ZHOU Ya-qi¹, FU Xiao², ZHENG Wen¹⁺

(1. Institute of Public Safety Big Data, College of Data Science, Taiyuan University of Technology,

Taiyuan 030060, China; 2. China Institute of Marine Technology and Economy,

Ship Culture Industry Development Research Center, Beijing 100081, China)

Abstract: Thyroid-associated ophthalmopathy (TAO) is a common chronic blinding orbital disease with poorly characterized early pathology. To solve the problem of misdiagnosis caused by subjective diagnostic bias of physicians in the TAO diagnosis process, a model Efficient-TAO based on the compound model scaling (CMS) method was proposed. Through optimizing the training process, the dynamic ReLU activation function, stochastic weight averaging function were improved to stimulate the performance. Direct training of ocular muscle CT image data was achieved by using image pre-processing algorithms. Experimental results show that the model achieves 98.34% classification accuracy and performs well in other algorithm evaluation metrics. The visualization results further validate the credibility of the Efficient-TAO algorithm for TAO classification.

Key words: TAO; Efficient-TAO; CMS; model optimization; medical image classification; image preprocessing; model credibility

0 引言

甲状腺相关眼病 (thyroid-associated ophthalmopathy, TAO) 又称甲状腺眼病或 Graves 眼病, 是自身免疫反应引起的慢性致盲性眼部疾病, 其发病率约为 (19~42)/10 万^[1-5]。目前还没有有效的方法能够阻止疾病的自然进程或完全治愈, 因此 TAO 早日诊断对于治疗方案的选择十分重要。TAO 在 CT 图像中的分类特征主要是眼肌厚薄和形态^[6], 通过影像学方法诊断 TAO, 不仅阅片耗时长, 且依

赖于医生的主观判断^[7], 不同层次医生对眼肌图像的解读存在偏差。医学影像领域医生的紧缺和巨大增量数据进一步加重了医生的负担^[8], 影响疾病的诊断效率和质量。

深度学习的快速发展推动了医学图像分类的应用研究^[9], 在许多诊疗阶段起着关键作用, 为医疗人员提供决策支持。现阶段针对 TAO 的分类模型仍有很大的挑战。本文首先通过 CMS 搜索基础网络模型, 在优化训练过程及参数的基础上做改进, 提出了 Efficient-TAO 实现正常与异常疾病特征的分类, 最后, 对分类结果的正确性进行验证。

收稿日期: 2023-03-23; **修订日期:** 2024-08-21

基金项目: 国家自然科学基金项目 (11702289); 国家重点研发计划 “科技助力经济 2020 专项” 基金项目 (RZ2000003782); 山西省关键核心技术和共性技术研发攻关专项基金项目 (2020XXX013)

作者简介: 周亚琪 (1996-), 男, 山西吕梁人, 硕士研究生, 研究方向为计算机视觉; 付潇 (1989-), 女, 河北张家口人, 硕士, 工程师, 研究方向为数据科学; +通讯作者: 郑文 (1985-), 男, 湖南岳阳人, 博士, 教授, 研究方向为机器学习、软物质物理、高性能计算及其应用、冲击动力学。E-mail: fuxiao@cimtec.net.cn

此外, 针对眼肌特征设计了预处理算法, 最大程度消除了图像中的干扰信息。

1 相关工作

卷积神经网络 (convolutional neural network, CNN) 是图像分类的重要研究方向^[10], 通常在一个固定的资源预算下开发, 然后在更多可用资源的情况下扩大规模以获得更好的准确性。Visual Geometry Group (VGG) 网络^[11]区别于此前的网络模型, 采用了小卷积核 (3×3), 更有利于保留图像性质, 验证了可以通过增加网络深度来提升性能。Going deeper with convolutions (GoogleNet)^[12]网络性能优于 VGG, 引入了 Inception 的结构作为基本卷积块; 将大卷积核拆分为小卷积核来增加网络的深度, 减少了参数量和计算量。Residual Network (ResNet)^[13]模型引入了跳跃连接 (skip connection), 通过 residual 模块解决了深层网络出现的退化问题, 能够训练出性能较好的极深模型。Dense convolutional network (DenseNet)^[14]在保证网络中层与层之间信息传输的同时直接将所有层连接起来, 通过特征在通道上的连接实现特征重用, 从而减少参数量提升效果。Tan 在 EfficientNet^[15]中提出一种简单高效的 CMS 方法, 通过一个复合系数均匀缩放深度、宽度、分辨率, 实现模型性能与准确率的平衡。以 EfficientNet 为核心的 COVID-19 自动诊断系统^[16]取得了良好的效果, 然而当输入图像较大

时过于占用 GPU 显存, 使得模型运行过程中波动较大。Wu 等通过多数投票法整合了 3 个子模型的输出^[17], 达到 94.87% 的 TAO 识别率, 但是多模型网络体积庞大、子网络结构不同, 加剧了图像预处理的工作量, 而且模型的参数更加复杂, 会导致误差放大影响 TAO 分类效果。Lee 等^[18]提出一种卷积神经网络, 用于区分不同程度的 TAO 患者, 但是所提的网络在正常和轻度症状中表现不佳, 而且模型无法验证网络的分类逻辑。

2 TAO 模型结构设计

2.1 Efficient-TAO 分类模型

以往的模型只注重分类的准确性, Efficient-TAO 模型同时考虑准确性与性能的平衡, 使用 CMS 复合系数统一缩放分辨率 (resolution)、网络深度 (depth) 和信道宽度 (width) 3 个维度, 搜索的基础模型比同期模型有更好的精度和效率, 更加关注特征细节的相关区域, 将参数和 FLOPS 降低了一个数量级。因此, 通过牺牲少量 FLOPS 改进激活函数提升模型性能。对于训练过程中的不稳定问题, 引入了随机权重平均 (stochastic weight averaging, SWA)^[19], 能够不增加开销的情况下, 提升模型的泛化性。此外, 模型还使用优化方法对训练过程进行优化, 通过改进训练方法能够有效的提升模型性能^[20]。模型结构如图 1 所示。




图 1 Efficient-TAO: 变换流程结构

模型结构分为 3 部分 (9 个 Stage), 参数属性见表 1。第一部分由一个步距为 2 的 3×3 卷积层、批归一化和激活函数构成。第二部分由 MBConv 结构堆叠组合, 参数表中

每个 MBConv 后的数字 1 或 6 为倍率因子, 第一个 1×1 的卷积层会将输入特征矩阵的通道扩充 n 倍, $k3 \times 3$ 、 $k5 \times 5$ 表示深度卷积核大小, Layers 表示 MBConv 结构的重复次

数, Stage2~Stage8 随着卷积的深入通道数增多, 模型能够更好的提取特征信息。第三部分由一个包含批归一化、激活函数 DY-ReLU 的 1×1 的卷积层, 一个平均池化层和一个全连接层组成。 1×1 的卷积层实现通道之间的完全交互, 池化层进行关键特征的融合降维, 最后由全连接层完成组合特征和分类的功能。

表 1 模型参数

Stage i	Operator $\hat{\mathcal{F}}_i$	Resolution $\hat{H}_i \times \hat{W}_i$	Channels $\hat{C}_i$	Layers $\hat{L}_i$
1	Conv3×3	224×224	48	1
2	MBConv1, k3×3	112×112	24	2
3	MBConv6, k3×3	112×112	32	4
4	MBConv6, k5×5	56×56	56	4
5	MBConv6, k3×3	28×28	112	6
6	MBConv6, k5×5	14×14	160	6
7	MBConv6, k5×5	14×14	272	8
8	MBConv6, k3×3	7×7	448	2
9	Conv1×1& Poling&FC	7×7	1792	1

2.1.1 CMS 方法

卷积神经网络可以抽象为若干 stage 的组合, 相同 stage 的 block 结构相同。如果使用函数来表示每一个卷积层, 那么卷积神经网络就可以表示为函数 $\mathcal{N}$, 所以神经网络函数定义如下

$$\mathcal{N} = \bigodot_{i=1 \dots s} \mathcal{F}_i^{L_i}(X_{(H_i, W_i, C_i)}) \quad (1)$$

i 是 stage 的索引, $\mathcal{F}_i$ 表示一个运算操作, $\mathcal{F}_i^{L_i}$ 的含义是 $\mathcal{F}_i$ 重复 L_i 次。 X 表示输入 stage 的特征矩阵, 其下标 H_i 、 W_i 表示 stage 的输入张量在深度 d 和宽度 w 上的尺度, C_i 表示输出张量的通道数 r 。卷积神经网络中 3 个扩张维度: width 对应增大网络宽度 C_i , depth 对应增大网络深度 L_i , resolution 对应增大分辨率 (H_i, W_i) 。scale up 的优化目标可以定义为

$$\begin{aligned} & \max_{d, w, r} \text{Accuracy}(\mathcal{N}(d, w, r)) \\ \text{s.t. } & \mathcal{N}(d, w, r) = \bigodot_{i=1 \dots s} \hat{\mathcal{F}}_i^{d \times \hat{L}_i}(X_{(r \times \hat{H}_i, r \times \hat{W}_i, r \times \hat{C}_i)}) \\ & \text{Memory}(\mathcal{N}) \leq \text{target_memory} \\ & \text{FLOPS}(\mathcal{N}) \leq \text{target_flops} \end{aligned} \quad (2)$$

在 baseline 的基础上给定宽度、深度、分辨率, 对卷积神经网络进行扩张, 使卷积神经网络的性能最优, 3 个维度的扩张系数的确定方法

$$\begin{aligned} \text{depth: } d &= \alpha^\phi \\ \text{width: } w &= \beta^\phi \\ \text{resolution: } r &= \gamma^\phi \\ \text{s.t. } & \alpha \cdot \beta^2 \cdot \gamma^2 \approx 2 \end{aligned}$$

$$\alpha \geq 1, \beta \geq 1, \gamma \geq 1 \quad (3)$$

ϕ 用于控制模型缩放的资源总量, 是一个预设的可控系数。CMS 方法通过计算求解得到 α 、 β 、 γ , 分别表示网络宽度、深度和分辨率的资源分配比例。最优缩放参数为 $\alpha=1.3$ 、 $\beta=1.2$ 、 $\gamma=1.05$ 。

2.1.2 改进方法

Efficient-TAO 模型使用的参数和 FLOPs 只有其它模型的 1/6, 因此通过额外增加 5%FLOPs 使模型获得性能提升具有可行性。Dynamic ReLU (DyReLU)^[21] 可以根据输入动态调整对应的分段激活函数, 能够显著提高网络的表达能力。其中空间共享模式 (DyReLU-B) 更适合图像分类任务, 函数结构如图 2 所示, 超函数 $\theta(x)$ 计算激活函数的参数, $f_{\theta(x)}(x)$ 使用 $\theta(x)$ 生成所有通道的激活函数。




图 2 DyReLU-B 结构

DyReLU 定义为多个线性函数的最大值, 其中线性系数 (a_c^k, b_c^k) 为辅助函数 $\theta(x)$ 的输出

$$\begin{aligned} y_c &= f_{\theta(x)}(x) = \max_{1 \leq k \leq K} \{a_c^k, b_c^k\} \\ \theta(x) &= [a_c^1, \dots, a_c^K, b_c^1, \dots, b_c^K] \end{aligned} \quad (4)$$

对于大小为 $C \times H \times W$ 的输入 x , 首先使用全局平均池化进行压缩, 然后在经过两个全连接层, 最后接一个归一化层将结果约束在 $[-1, 1]$, 归一化层使用 $2\sigma(x) - 1$, σ 为 Sigmoid 函数。子网输出通道数为 $2KC$, 分别对应 $a_c^{1:K}$ 和 $b_c^{1:K}$ 的残差。辅助函数的更新如下

$$\begin{aligned} a_c^k(x) &= a_c^k + \lambda_a \Delta a_c^k(x) \\ b_c^k(x) &= b_c^k + \lambda_b \Delta b_c^k(x) \end{aligned} \quad (5)$$

a_c^k 和 b_c^k 为 a_c^k 和 b_c^k 的初始值, λ_a 和 λ_b 是用来控制残差大小的标量。当 $K=2$ 时, 默认参数为: $\alpha^1 = 1$, $\alpha^2 = \beta^1 = \beta^2 = 0$, $\lambda_a = 1.0$, $\lambda_b = 0.5$ 。

为解决模型训练过程中的权重震荡问题, 模型加入了

SWA 机制。首先给定算法的超参数循环周期和周期学习率的上下界, 然后每个循环周期进行一次权重平均, 最后使用平均的权重进行推理得到最终的神经网络权重, 从而使得最终权重位于 flat 曲面更中心的位置。SWA 具有更广泛的解, 能够改善 Efficient-TAO 模型的泛化能力, 耗费的资源可忽略不计, 仅额外增加了一个周期性的权重平均。

2.2 TAO 图像预处理算法

实验数据集由山西医科大学第二医院影像医学科提供, 总样本数据为 663 个 CT 成像水平位图, 样本数据存在不同程度不同类型的异常表现, 其中正常眼肌 366 例, 异常眼肌 297 例。TAO 类别如图 3 所示, 图 3 (a) 异常 abnormal、图 3 (b) 正常 normal。




图3 眼肌 CT 数据

TAO 眼眶内的临床特征主要是多条程度不同的眼外肌受累, 其中眼球左右方位的称为内外直肌, 位于眼球上下方位的称为上下直肌。一项针对 TAO 的研究结果表明: 2215 例患者中下直肌异常占 79.9% (3539 眼), 其次是上直肌 55.6%、内侧直肌 49.5% 和外侧直肌 28.2%。此外, 1212 只眼睛 (27.4%) 有一只眼外肌增大, 20.1% 有两只眼外肌增大, 20.3% 有 3 只眼外肌增大, 21.0% 有 4 只眼外肌全部增大^[5]。因此, 以眼肌特征进行分类可以有效辅助诊断。

数据预处理^[22]可以提高 Efficient-TAO 分类结果的正确性与准确性, 在保留细节特征的同时减少计算量。目前医学图像的预处理多通过人工方式, 费时费力, 因此模型中设计了 TAO 预处理算法, 实现了原始数据集的自动处理, 提高了数据预处理能力和效率。CT 数据集中患者头部大小和位置存在差异, 且分类关键区域—眼眶部分仅占据整个图像的 1/5, 预处理的目的是去除眼肌之外的无关信息。预处理流程如图 1 左侧所示, 数据预处理算法设计如下:

(1) 将转换为灰度图像; 使用高斯滤波器执行去噪, 减小像素间差异。

(2) 提取图像梯度, 通过 Sobel 算子计算 x、y 方向上的梯度; 再次去噪、平滑图像, 将像素替换为周围像素的均值, 使图像平滑并替代那些强度变化明显的区域, 以降低图像变化率。

(3) 图像数据二值化, 通过数值边界将像素转换为纯黑与纯白两种色域。

(4) 进行若干次形态学腐蚀与膨胀, 去除干扰图像部分, 保留头部完整区域。

(5) 寻找区域的最大宽高, 确定图像的矩形轮廓。

(6) 像素反转, 清除区域外围干扰像素; 缩小范围, 从图像中剥离出眼部区域的完整轮廓。

(7) 统一图像大小比例, 固定特征区域在图像中的绝对位置。

(8) 裁剪出眼眶区域。

小样本数据集容易出现过拟合或者泛化能力不强的问题。在保证数据有效性的前提下, 模型中使用数据增强方法扩充 TAO 数据集, 使数据量达到 10 000 张, 并有效避免了两类样本的不均衡分布。TAO 图像在位置、角度和大小方面存在明显差异, 因此使用几何变换不会改变 TAO 的病理特征, 能够有效增强数据, 几何变换类型见表 2。

表2 数据增强参数

增强类型	参数设置
翻转方向	水平
随机裁剪	15 px
旋转角度	5°
平移	X/Y 轴 10 px

3 实验结果分析

3.1 实验环境配置

实验硬件环境为基于 HPC 系统架构技术设计的服务器平台: Linux 操作系统, GPU 为 NVIDIA Tesla V100 SXM2 16 GB * 8, Intel(R) Xeon(R) Gold 6142 CPU @ 2.60 GHz 处理器。采用 python3.7 作为编程语言, 使用 Tensorflow 2.0 深度学习框架。实验数据集包括正常和异常两类样本, 其中训练集、验证集和测试集以比例 7:2:1 划分。Efficient-TAO 模型训练参数如下: CT 图像尺寸为 512×512, 输入数据的分辨率为 380×380, batch size: 16, epochs: 120, 初始学习率 0.006。

使用的评价指标主要有准确率 Accuracy、浮点运算次数 (floating-point operations, FLOPs) 和参数量 Params。计算评价指标时, True Positive (TP) 表示预测为正常的正常类; True Negative (TN) 表示预测为异常的异常类; False Positive (FP) 表示预测为正常的异常类; False Negative (FN) 表示预测为异常的正常类。准确率 (Accuracy) 表示模型预测准确的概率

$$Accuracy = \frac{TP + TN}{TP + FP + TN + FN} \quad (6)$$

FLOPs: 表示计算量, 用来衡量算法/模型的复杂度,

常用作神经网络模型速度的间接衡量标准。

Params：是指模型训练中需要训练的参数总数，用来衡量模型的大小（计算空间复杂度）。

3.2 模型改进验证

为了验证模型的改进和训练优化效果，模型通过消融实验分别对 DyReLU、SWA 改进和训练优化效果进行了验证，‘+’ 标记改进项，所有结果都取 2 次运行的平均值。

图 4 对比了基础缩放模型与引入 DyReLU-B 模型的性能。通过曲线可以观察到改进后的模型准确率均高于基础模型且增速稳定，基础模型准确率为 95.04%，改进后模型准确率提升到 97.52%。




图 4 DyReLU 改进

图 5 对比了 SWA 改进前后的模型训练过程。基础模型收敛过程中存在明显震荡，loss 值稳定在 0.317；加入 SWA 后 loss 以稳定速率收敛，震荡幅度非常小，loss 稳定在 0.205。加入 SWA 后不仅可以缓解训练中的权重震荡问题，而且可以在一定程度上提升模型性能。




图 5 SWA 改进

在现有优化基础上（SE、Dropout 等），模型使用了表 3 所示的训练措施进行优化。通过增加训练次数对模型性能提升不大，所以实验使用 120 个 epoch 的结果进行分析，不再增加训练次数；采用余弦退火调整学习率，对训练效果有明显的改善；标签平滑方法是一种正则化技术，能够影响分类概率增强学习过程的泛化，对整体性能有一定的

提升；权重衰减对数据的拟合更好，性能提升约 0.2。多项训练优化综合增益为 1.1，达到了模型性能提升总量的 30%，因此通过有效的训练优化能够提高模型的性能。训练优化项见表 3。

表 3 模型训练优化

优化措施	准确率/%	Δ
基础模型	97.52	—
+余弦退火	97.82	↑0.3
+增加训练次数	97.42	↑0.1
+标签平滑	98.02	↑0.5
+权重衰减	97.72	↑0.2

3.3 模型结果对比

Efficient-TAO 与其它网络模型在分类准确率、网络参数量和 FLOPs 进行对比，如表 4 所示。

表 4 多模型性能比较

类型	准确率/%	参数量/M	FLOPs/B
VGG-16 ^[11]	75.2	59.75	13
GoogleNet ^[12]	76.6	48	5.7
ResNet-152 ^[13]	89.2	60	11
DenseNet-264 ^[14]	93.9	34.9	6
EfficientNet ^[15]	95.04	19	4.2
Efficient-TAO	98.34	20	4.4

VGG 与 GoogleNet 模型准确率不高，GoogleNet 通过 Inception 结构的引入减少了参数量和计算量；ResNet 在此基础上大幅度提高了准确率 12.6%；DenseNet 突破了深度问题，准确率提升较大 4.7%，但是训练参数体量变化不大；EfficientNet 相比单维扩展模型，在准确率、参数量和计算量上有综合提升。Efficient-TAO 相比 EfficientNet 虽然参数量有所增加，但是准确率提升了 3.3%。结果表明 Efficient-TAO 模型在分类效果上优于其它方法。

3.4 模型可信度分析

实验分析了 100 例样本的类别分布情况，分布排列情况如图 6 所示。TAO 预测正确结果的可能性均值为 0.85，中位区间可能性均值为 0.83，由图中折线可以看到可能性在 0.72~0.79 和 0.79~0.86 的数量在总样本数中占一半以上，两个中位区间。可能性 0.86~1 的部分占到总样本数的 32%。TAO 分类结果与可能性分布基本吻合，因此，通过该算法辅助诊断与决策具有可信度。

Efficient-TAO 通过 Gradient-weighted Class Activation Mapping (Grad-CAM)^[23] 可视化分类特征。Grad-CAM 是使用目标概念（眼肌）的梯度流入最终的卷积层，生成一




图6 样本分布排列

个粗定位特征图,突出显示图像中的重要区域以预测概念。根据模型的特征提取器和分类器,从CNN的模型中基于决策产生“可视化解释”,Grad-CAM基于最后一层特征图进行可视化。生成的CAM大小与最后一层特征图的大小一致,接着进行上采样即可得到与原图大小一致的图,如图7所示。




图7 可视化分类特征

图7(a)中的高亮区域集中于左上(0,2)到右下(2,4)的矩形范围内,(1,2)和(1,4)对应叠加效果图中的眼肌区域,因此可以验证模型的正确分类是基于眼肌的类间相关性特征。

4 结束语

此项工作旨在解决TAO诊断中由于主观偏差性导致的错诊、误诊问题。提出了一种基于CMS方法改进的模型Efficient-TAO,包括数据预处理算法和分类模型。TAO预处理算法改善了繁琐的人工处理数据过程,提高了数据处理效率,能够直接将原始数据用于模型训练。模型通过DyReLU-B和SWA优化器等改进,并通过训练优化方法提升了分类性能。消融实验验证了改进的可行性和有效性,与其它模型相比Efficient-TAO兼顾准确性与性能,分类准确率达到98.34%。此外,样本可能性分布和特征提取可视化结果进一步验证了Efficient-TAO分类模型的可信度。实验结果充分表明了所提方法的优越性,可以根据眼肌特征对TAO进行分类,有效解决诊断决策中的偏差问题,帮助患者得到及时治疗。目前模型在训练过程中还存在占用

GPU过多的情况,后续工作将对这部分工作进行研究,提高模型在TAO分类中的实际应用能力。

参考文献:

- [1] FENG Xiaoting, LI Zhangfang, SHEN Jie. Progress in the diagnosis and management of thyroid-associated ophthalmopathy [J]. Chinese Journal of Practical Internal Medicine, 2019, 39 (4): 384-388 (in Chinese). [冯晓婷, 李章芳, 沈洁. 甲状腺相关性眼病的诊疗进展 [J]. 中国实用内科杂志, 2019, 39 (4): 384-388.]
- [2] Hoppe E, Lee ACH, Hoppe D, et al. Predictive factors for changes in quality of life after steroid treatment for active moderate-to-severe Graves' orbitopathy: A prospective trial [J]. European Thyroid Journal, 2021, 9 (6): 313-320.
- [3] Cockerham KP, Padnick-Silver L, Stuert N, et al. Quality of life in patients with chronic thyroid eye disease in the united states [J]. Ophthalmology and Therapy, 2021, 10: 975-987.
- [4] Bruscolini A, Sacchetti M, La Cava M, et al. Quality of life and neuropsychiatric disorders in patients with Graves' orbitopathy: Current concepts [J]. Autoimmunity Reviews, 2018, 17 (7): 639-643.
- [5] Du B, Wang Y, Yang M, et al. Clinical features and clinical course of thyroid-associated ophthalmopathy: A case series of 3620 Chinese cases [J]. Eye, 2021, 35 (8): 2294-2301.
- [6] Li Z, Cestari DM, Fortin E. Thyroid eye disease: What is new to know? [J]. Current Opinion in Ophthalmology, 2018, 29 (6): 528-534.
- [7] WANG Dandan, QIN Qin, LI Rui, et al. Research progresses of imaging methods in diagnosis of thyroid-associated ophthalmopathy [J]. Chinese Journal of Medical Imaging Technology, 2020, 36 (11): 1746-1749 (in Chinese). [王丹丹, 秦琴, 李芮, 等. 甲状腺相关性眼病影像学研究进展 [J]. 中国医学影像技术, 2020, 36 (11): 1746-1749.]
- [8] XIAO Yi, LIU Shiyuan. Current status and challenges of artificial intelligence industrialization in medical imaging [J]. Oncoradiology, 2019, 28 (3): 129-133 (in Chinese). [萧毅, 刘士远. 医学影像人工智能产业化的现状及面临的挑战 [J]. 肿瘤影像学, 2019, 28 (3): 129-133.]
- [9] Zhang J, Xie Y, Wu Q, et al. Medical image classification using synergic deep learning [J]. Medical Image Analysis, 2019, 54: 10-19.
- [10] Dhillon A, Verma GK. Convolutional neural network: A review of models, methodologies and applications to object detection [J]. Progress in Artificial Intelligence, 2020, 9 (2): 85-112.
- [11] Albashish D, Al-Sayyed R, Abdullah A, et al. Deep CNN model based on VGG16 for breast cancer classification [C] // International Conference on Information Technology. IEEE, 2021: 805-810.

- [12] Sekhar A, Biswas S, Hazra R, et al. Brain tumor classification using fine-tuned GoogLeNet features and machine learning algorithms; IoMT enabled CAD system [J]. IEEE Journal of Biomedical and Health Informatics, 2021, 26 (3): 983-991.
- [13] Chen Y, Lin Y, Xu X, et al. Classification of lungs infected COVID-19 images based on inception-ResNet [J]. Computer Methods and Programs in Biomedicine, 2022, 225: 107053.
- [14] Singh D, Kumar V, Kaur M. Densely connected convolutional networks-based COVID-19 screening model [J]. Applied Intelligence, 2021, 51: 3044-3051.
- [15] Tan M, Le Q. Efficientnet; Rethinking model scaling for convolutional neural networks [C] //International Conference on Machine Learning. PMLR, 2019: 6105-6114.
- [16] Marques G, Agarwal D, de la Torre Díez I. Automated medical diagnosis of COVID-19 through EfficientNet convolutional neural network [J]. Applied Soft Computing, 2020, 96: 106691.
- [17] Wu C, Jin J. Application of deep learning in the identification of TAO [C] //MIPPR 2017: Parallel Processing of Images and Optimization Techniques; and Medical Imaging. SPIE, 2018: 81-86.
- [18] Lee J, Seo W, Park J, et al. Neural network-based method for diagnosis and severity assessment of Graves' orbitopathy using orbital computed tomography [J]. Scientific Reports, 2022, 12 (1): 12071.
- [19] Izmailov P, Podoprikin D, Garipov T, et al. Averaging weights leads to wider optima and better generalization [C] //34th Conference on Uncertainty in Artificial Intelligence, 2018: 876-885.
- [20] Bello I, Fedus W, Du X, et al. Revisiting resnets: Improved training and scaling strategies [J]. Advances in Neural Information Processing Systems, 2021, 34: 22614-22627.
- [21] Chen Y, Dai X, Liu M, et al. Dynamic relu [C] //European Conference on Computer Vision. Springer, Cham, 2020: 351-367.
- [22] Cordonnier JB, Mahendran A, Dosovitskiy A, et al. Differentiable patch selection for image recognition [C] //Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition, 2021: 2351-2360.
- [23] Jiang H, Xu J, Shi R, et al. A multi-label deep learning model with interpretable grad-CAM for diabetic retinopathy classification [C] //42nd Annual International Conference of the IEEE Engineering in Medicine & Biology Society, 2020: 1560-1563.